Pemanfaatan Machine Learning, Deep Learning, dan Large Language Model dalam Interpretasi Elektrokardiogram (EKG)

Nov 2, 2026 · @affan

Makalah

Disusun oleh: Muhammad Affan Hassya Purnomo

NIM: 21305032610142 · Kelompok: I2611

Program Studi Kedokteran, Fakultas Kedokteran, Universitas Sebelas Maret, Surakarta — 2026

Abstrak

Kecerdasan artifisial (AI) telah mengubah EKG dari alat diagnosis listrik jantung menjadi biomarker non-invasif yang mampu mendeteksi kondisi yang tidak terlihat oleh mata manusia. Model *deep learning* berbasis *convolutional neural network* (CNN) mencapai kinerja setara kardiolog dalam klasifikasi aritmia (F1 0,837 vs 0,780) dan mampu mendeteksi disfungsi ventrikel kiri dari EKG 12 sadapan dengan AUC 0,93. Uji klinis acak EAGLE membuktikan bahwa AI-EKG meningkatkan diagnosis fraksi ejeksi rendah di layanan primer (OR 1,32). Sebaliknya, *large language model* (LLM) multimodal generalis yang membaca gambar EKG masih belum andal secara klinis, dengan akurasi keseluruhan sekitar 50–65% dan sensitivitas rendah untuk fibrilasi atrium serta deviasi segmen ST. Makalah ini membahas dasar teori, aplikasi, bukti kinerja, keterbatasan, aspek etik, dan relevansinya bagi sistem kesehatan Indonesia.

Sebagai implementasi, penulis membangun model 1D ResNet pada 21.388 EKG PTB-XL. Model ini mencapai macro AUC 0,927 untuk 5 kelompok diagnosis, mengungguli *machine learning* klasik (0,887), dan mengenali 53 kode diagnosis rinci (macro AUC 0,920). Model dilengkapi pengukuran berbasis aturan untuk menghasilkan laporan 8 kategori dan dikemas sebagai aplikasi web. Uji pada data Holter dan EKG hasil digitalisasi gambar menunjukkan pentingnya validasi eksternal.

Kata kunci: elektrokardiogram, *machine learning*, *deep learning*, *convolutional neural network*, *large language model*, AI-EKG

BAB I — Pendahuluan

1.1 Latar Belakang

Penyakit kardiovaskular adalah penyebab kematian utama di dunia dan di Indonesia. EKG 12 sadapan merupakan pemeriksaan jantung yang paling murah, cepat, dan tersedia luas, dari puskesmas hingga rumah sakit rujukan. Namun, interpretasinya membutuhkan keahlian dan rentan terhadap variasi antarpembaca.

Interpretasi komputer konvensional berbasis aturan (*rule-based*) sudah lama dipakai pada mesin EKG, tetapi akurasinya terbatas. Kemajuan *deep learning* dan ketersediaan jutaan EKG digital yang terhubung dengan data klinis memungkinkan AI mengenali pola halus yang tidak dapat dikenali manusia [1]. Sejak 2023, LLM multimodal yang mampu membaca gambar juga mulai diuji untuk menafsirkan EKG [10, 11].

Sebagai calon dokter, mahasiswa kedokteran perlu memahami cara kerja, kekuatan, dan batasan teknologi ini agar mampu memakainya secara kritis dan aman.

1.2 Rumusan Masalah

1. Apa perbedaan konsep *machine learning*, *deep learning*, dan LLM dalam konteks analisis EKG?
2. Apa saja aplikasi AI dalam diagnosis berbasis EKG dan bagaimana bukti kinerjanya?
3. Bagaimana kinerja LLM multimodal dibandingkan model *deep learning* khusus EKG?
4. Apa tantangan, aspek etik, dan relevansinya bagi pelayanan kesehatan di Indonesia?
5. Bagaimana kinerja model *deep learning* yang dibangun sendiri pada data PTB-XL dan data eksternal?

1.3 Tujuan

1. Menjelaskan dasar teori EKG dan metode AI yang digunakan untuk menganalisisnya.
2. Menguraikan aplikasi klinis AI-EKG beserta data kinerjanya.
3. Membandingkan model *deep learning* khusus dengan LLM multimodal generalis.
4. Mengidentifikasi keterbatasan, isu etik, dan peluang penerapan di Indonesia.
5. Membangun dan mengevaluasi sistem interpretasi EKG sendiri (model *deep learning* + pengukuran berbasis aturan) beserta aplikasi webnya.

1.4 Manfaat

- **Bagi mahasiswa:** memperluas wawasan tentang kedokteran digital dan dasar penilaian kritis terhadap alat diagnosis berbasis AI.

- **Bagi institusi pendidikan:** bahan diskusi untuk integrasi literasi AI dalam kurikulum kedokteran.
- **Bagi layanan kesehatan:** gambaran peluang AI-EKG untuk skrining di fasilitas dengan keterbatasan kardiolog.

BAB II — Tinjauan Pustaka

2.1 Dasar Elektrokardiogram

EKG merekam aktivitas listrik jantung dari permukaan tubuh. EKG standar terdiri atas 12 sadapan (I, II, III, aVR, aVL, aVF, V1–V6) yang direkam selama 10 detik, biasanya dengan frekuensi sampling 250–500 Hz.

Komponen utama yang dinilai:

- **Gelombang P:** depolarisasi atrium.
- **Interval PR:** waktu konduksi atrium ke ventrikel melalui nodus AV (normal 120–200 ms).
- **Kompleks QRS:** depolarisasi ventrikel (normal < 120 ms).
- **Segmen ST dan gelombang T:** repolarisasi ventrikel; perubahan di sini menandakan iskemia, infark, atau gangguan elektrolit.
- **Interval QT/QTc:** durasi total depolarisasi dan repolarisasi ventrikel.

Interpretasi sistematis meliputi irama, laju, aksis, interval, morfologi, serta tanda hipertrofi dan iskemia. Pada tingkat sel, bentuk gelombang ini mencerminkan potensial aksi kardiomiosit yang diatur kanal ion Na^+, K^+, dan Ca^{2+}. Karena itu, kelainan struktural atau metabolik dapat meninggalkan “jejak” halus pada sinyal EKG.

2.2 Machine Learning, Deep Learning, dan LLM

Aspek	Machine learning klasik	Deep learning (CNN, RNN, Transformer)	LLM multimodal
Input	Fitur yang diekstraksi manual (durasi QRS, interval RR, QTc)	Sinyal mentah EKG (deret waktu) atau gambar	Gambar EKG + teks (riwayat, pertanyaan)
Contoh algoritma	*Support vector machine*, *random forest*, *gradient boosting*	CNN 1D, ResNet, LSTM, Transformer	GPT, Gemini, Claude; model khusus seperti PULSE

Aspek	Machine learning klasik	Deep learning (CNN, RNN, Transformer)	LLM multimodal
Kebutuhan data	Ribuan sampel berlabel	Ratusan ribu–jutaan EKG berlabel	Dilatih pada data umum; dapat diadaptasi dengan sedikit contoh (*few-shot*)
Kelebihan	Mudah ditafsirkan	Akurasi tinggi; menemukan pola tersembunyi	Fleksibel, dapat menjelaskan alasan dalam bahasa alami
Kekurangan	Terbatas pada fitur yang dirancang manusia	"Kotak hitam", butuh data besar	Akurasi EKG masih rendah, jawaban dapat berubah antarpercobaan

Machine learning (ML) adalah cabang AI yang membuat komputer belajar pola dari data tanpa diprogram aturan secara eksplisit. Pada ML klasik, manusia terlebih dahulu menentukan fitur yang dianggap penting.

Deep learning (DL) adalah bagian dari ML yang menggunakan jaringan saraf tiruan berlapis banyak. CNN sangat cocok untuk EKG karena filter konvolusinya mengenali pola lokal (misalnya bentuk QRS) lalu menggabungkannya menjadi pola yang makin kompleks. Model belajar langsung dari sinyal mentah (*end-to-end*), sehingga dapat menangkap informasi yang tidak tercakup dalam kriteria diagnosis klasik [1].

Large language model (LLM) adalah model Transformer yang dilatih pada korpus teks sangat besar. Versi multimodal (*vision-language model*) juga dapat menerima gambar, sehingga dapat diberi foto atau hasil cetak EKG. LLM tidak dirancang khusus untuk sinyal EKG, tetapi dapat diadaptasi melalui *prompting*, contoh dalam *prompt*, atau pelatihan lanjutan [13, 14].

2.3 Alur Pengembangan Model AI-EKG

1. **Pengumpulan data:** EKG digital dipasangkan dengan label rujukan (diagnosis kardiolog, hasil ekokardiografi, kadar kalium serum).
2. **Pra-pemrosesan:** penyaringan *noise* dan *baseline wander*, normalisasi, penyeragaman frekuensi sampling.
3. **Pembagian data:** set pelatihan, validasi, dan uji (misalnya rasio 7:1:2 [6]).
4. **Pelatihan model:** jaringan menyesuaikan bobotnya agar prediksi mendekati label.
5. **Evaluasi:** AUC, sensitivitas, spesifisitas, nilai F1, dan validasi eksternal di populasi lain.
6. **Uji klinis dan implementasi:** penilaian dampak nyata pada keputusan klinis dan luaran pasien [5].

Ukuran kinerja yang paling sering dipakai adalah AUC (*area under the ROC curve*): nilai 0,5 setara tebakan acak dan 1,0 berarti sempurna.

BAB III — Pembahasan

3.1 Aplikasi Deep Learning pada EKG

Aplikasi AI-EKG terbagi dua: (a) **mengotomatisasi interpretasi yang biasa dilakukan dokter**, seperti klasifikasi aritmia, dan (b) **mendeteksi kondisi yang tidak dapat dilihat manusia dari EKG**, seperti fraksi ejeksi rendah atau hiperkalemia pada EKG yang tampak normal [1].

Studi	Tugas	Data	Hasil utama
Hannun dkk., 2019 [2]	Klasifikasi 12 kelas irama dari EKG 1 sadapan	91.232 EKG, 53.549 pasien	AUC rata-rata 0,97; F1 0,837 vs kardiolog 0,780
Ribeiro dkk., 2020 [3]	6 kelainan EKG 12 sadapan	> 2 juta EKG (Brasil)	F1 > 80%, spesifisitas > 99%; mengungguli residen kardiologi
Attia dkk., 2019a [4]	Disfungsi ventrikel kiri (EF ⩽ 35%)	Latih 44.959; uji 52.870 pasien	AUC 0,93; sensitivitas 86,3%; spesifisitas 85,7%
Attia dkk., 2019b [6]	Fibrilasi atrium dari EKG irama sinus	180.922 pasien; 649.931 EKG	AUC 0,87; sensitivitas 79,0%; spesifisitas 79,5%
Galloway dkk., 2019 [7]	Hiperkalemia pada PGK	1.576.581 EKG pelatihan	AUC 0,853–0,883 dengan sadapan I dan II saja
Attia dkk., 2019c [8]	Usia dan jenis kelamin	499.727 latih; 275.056 uji	Jenis kelamin AUC 0,97; galat usia 6,9 ± 5,6 tahun

a. Klasifikasi aritmia. Hannun dkk. menunjukkan bahwa satu jaringan *end-to-end* mampu mengklasifikasi 12 jenis irama setara kardiolog. Pada spesifisitas yang sama, sensitivitas model melampaui rata-rata kardiolog untuk semua kelas irama [2]. Ribeiro dkk. memperluas temuan ini ke EKG 12 sadapan dengan lebih dari 2 juta rekaman dari jaringan telemedisin Minas Gerais [3].

b. Disfungsi ventrikel kiri. Disfungsi ventrikel kiri asimtomatik terdapat pada 3–6% populasi dan dapat diobati bila ditemukan. Model CNN Mayo Clinic mendeteksinya dari EKG saja dengan AUC 0,93. Pasien tanpa disfungsi yang hasil AI-nya positif memiliki risiko 4,1 kali lipat mengalami disfungsi di kemudian hari [4]. Ini menandakan bahwa model menangkap perubahan elektris yang mendahului perubahan struktural.

c. Fibrilasi atrium tersembunyi. Model dapat mengenali "jejak" fibrilasi atrium paroksismal pada EKG yang sedang dalam irama sinus normal (AUC 0,87) [6]. Hal ini berguna untuk menyaring pasien stroke kriptogenik yang membutuhkan pemantauan irama jangka panjang.

d. Gangguan elektrolit. Hiperkalemia sering asimtomatik pada pasien penyakit ginjal kronik (PGK). Model Galloway dkk. mencapai sensitivitas sekitar 90% hanya dengan dua sadapan, sehingga berpotensi dipakai pada perangkat genggam [7].

e. Usia biologis. Selisih antara "usia EKG" prediksi AI dan usia kronologis > 7 tahun berhubungan dengan EF rendah, hipertensi, dan penyakit koroner, sehingga berpotensi menjadi penanda kesehatan kardiovaskular secara umum [8].

3.2 Bukti Uji Klinis: EAGLE

Kinerja tinggi di data retrospektif belum tentu berarti manfaat klinis. Uji klinis acak klaster EAGLE melibatkan 120 tim layanan primer, 358 klinisi, dan 22.641 pasien dewasa tanpa riwayat gagal jantung [5].

- Diagnosis baru EF rendah (⩽ 50%) dalam 90 hari meningkat dari 1,6% (kontrol) menjadi 2,1% (intervensi); OR 1,32; P = 0,007.
- Pada pasien dengan AI-EKG positif (6% kohort), diagnosis meningkat dari 14,5% menjadi 19,5%.
- Penggunaan ekokardiografi keseluruhan tidak berbeda bermakna (18,2% vs 19,2%), tetapi lebih terarah pada pasien dengan hasil AI positif (38,1% vs 49,6%).

Artinya, AI-EKG membantu dokter umum menemukan lebih banyak kasus tanpa membebani sistem dengan pemeriksaan berlebihan [5].

3.3 LLM Multimodal dalam Interpretasi EKG

LLM generalis menarik karena dapat menerima foto EKG dan menjelaskan alasan dalam bahasa alami. Namun, bukti 2026 menunjukkan kinerjanya masih jauh di bawah model DL khusus maupun algoritma mesin EKG.

Studi	Model	Data	Temuan utama
Soubh dkk., 2026 [10]	6 LLM generalis (ChatGPT-5, Gemini 2.5, Claude Opus-4.1, dll.) + 2 model khusus	70 gambar EKG	Akurasi seimbang 50,1–61,8%; sensitivitas FA ⩽ 11,1%; deviasi ST < 25%; κ ⩽ 0,39

Studi	Model	Data	Temuan utama
Stelling dkk., 2026 [11]	5 LLM (ChatGPT-5.3, Gemini 3.1 Pro, Claude Opus 4.6, dll.)	13 EKG × 5 percobaan	Akurasi 52,3–64,9%; ST/T 20–41,5%; galat laju jantung 14,8–46,7 bpm
Legendre dkk., 2026 [12]	3 LLM vs algoritma mesin EKG	615 EKG pra-rumah sakit (dugaan STEMI)	Gemini sensitivitas 95,3% tetapi spesifisitas 9,4%; mesin EKG lebih seimbang (67,7% / 64,2%)
Jiang dkk., 2026 [15]	GPT-4o, Gemini 2.5 Pro dengan *few-shot*	928 gambar EKG	Akurasi GPT-4o meningkat hingga 0,829 dengan 5 contoh
Cheng dkk., 2026 [13]	ECG-R1 (VLM 2B + *reinforcement learning*)	12.917 kasus inversi gelombang T	Akurasi 75,2%; AUC 0,842; disertai jejak penalaran

Pola yang konsisten dari studi-studi tersebut:

1. **LLM generalis belum aman dipakai mandiri.** Sensitivitas untuk temuan kritis (FA, blok AV derajat 1, QTc memanjang, deviasi ST) sangat rendah [10, 11]. Untuk keputusan aktivasi kateterisasi darurat, LLM menghasilkan terlalu banyak positif palsu [12].
2. **Jawaban tidak konsisten.** Model yang sama dapat memberi jawaban berbeda pada EKG yang sama di percobaan berbeda [11].
3. **Adaptasi meningkatkan kinerja.** Pemberian contoh (*few-shot*) dan pelatihan khusus EKG memperbaiki akurasi [13–15]. Pada sindrom Brugada yang datanya langka, VLM dengan sedikit contoh bahkan menyaingi model ML khusus [14].
4. **Keunggulan utama LLM adalah penjelasan.** Kerangka bertahap yang mengekstraksi fitur EKG lalu menggabungkannya dengan aturan deterministik memberi proses diagnosis yang dapat ditelusuri, dengan kinerja setara CNN untuk lokalisasi asal PVC (AUC 0,720 vs 0,712) [16].

Perbedaan mendasar: model DL khusus membaca **sinyal digital** beresolusi tinggi dan dilatih pada jutaan EKG berlabel, sedangkan LLM generalis umumnya membaca **gambar** dan tidak dilatih khusus untuk pengukuran milidetik.

3.4 Tantangan dan Keterbatasan

- **Generalisasi.** Banyak model dikembangkan di satu institusi (misalnya Mayo Clinic) dan perlu divalidasi pada populasi, mesin EKG, dan kondisi rekaman yang berbeda.

- **Bias.** Model dapat berkinerja berbeda antar subkelompok. Studi Harmon dkk. menunjukkan AI-EKG disfungsi ventrikel kiri relatif stabil antarkelompok ras (AUC 0,90–0,92), tetapi turun pada blok cabang berkas kiri (AUC 0,79) [9].
- **Kotak hitam.** Keputusan CNN sulit dijelaskan; metode seperti *saliency map* dan pendekatan LLM berbasis penalaran sedang dikembangkan [13, 16].
- **Kualitas input.** Foto EKG yang miring, buram, atau berbayangan menurunkan akurasi, terutama pada model berbasis gambar.
- **Prevalensi rendah.** Pada skrining populasi, nilai prediksi positif tetap rendah meski spesifisitas tinggi; contohnya F1 hanya 39,2% pada deteksi FA dari irama sinus [6].

3.5 Aspek Etik dan Regulasi

1. **Tanggung jawab klinis** tetap pada dokter; AI adalah alat bantu keputusan, bukan pengganti.
2. **Privasi data:** EKG adalah data kesehatan pribadi; di Indonesia tunduk pada UU No. 27 Tahun 2022 tentang Pelindungan Data Pribadi.
3. **Persetujuan dan transparansi:** pasien berhak tahu bila keputusan klinis dibantu AI.
4. **Izin edar:** perangkat lunak medis memerlukan evaluasi regulator sebelum dipakai klinis; chatbot umum tidak dirancang dan tidak disetujui sebagai alat diagnosis.
5. **Ketergantungan berlebihan (*automation bias*):** dokter dapat mengikuti saran AI yang salah; kemampuan membaca EKG secara mandiri tetap wajib dikuasai.

3.6 Relevansi bagi Indonesia

Indonesia memiliki wilayah kepulauan yang luas dan distribusi kardiolog yang terkonsentrasi di kota besar. EKG sudah tersedia di banyak puskesmas, tetapi pembacanya sering dokter umum. Peluang penerapan AI-EKG antara lain:

- **Triase di layanan primer:** menandai EKG yang dicurigai STEMI, aritmia berbahaya, atau EF rendah untuk dirujuk segera.
- **Telekardiologi:** model DL membantu menyaring ribuan EKG kiriman sebelum dibaca kardiolog, seperti jaringan telemedisin Minas Gerais di Brasil [3].
- **Skrining PGK dan hiperkalemia** dengan perangkat sadapan terbatas [7].
- **Pendidikan:** LLM dapat dipakai sebagai tutor untuk menjelaskan konsep EKG, tetapi hasil interpretasinya harus diverifikasi dengan buku ajar dan pengajar.

Syarat utama sebelum adopsi luas adalah validasi lokal pada populasi Indonesia, karena belum ada model besar yang divalidasi khusus pada data EKG Indonesia dalam literatur yang ditelusuri.

BAB IV — Metode Implementasi: Pembaca EKG 12 Sadapan

Untuk menguji konsep di BAB II–III secara langsung, penulis membangun sistem interpretasi EKG sendiri: model *deep learning* yang membaca sinyal EKG 12 sadapan, pengukuran otomatis berbasis aturan, serta aplikasi web yang menghasilkan laporan diagnosis. Seluruh kode tersedia di repositori GitHub neccrr/ekg-readings-model.

4.1 Desain dan Alur Pengembangan

Data latih utama adalah **PTB-XL v1.0.3** [17]: 21.799 EKG 12 sadapan berdurasi 10 detik dari 18.869 pasien, dianotasi oleh hingga dua kardiolog dengan 71 kode SCP-ECG. Dipakai versi 100 Hz dan 21.388 rekaman yang memiliki label diagnostik. Pembagian data mengikuti fold standar sehingga pasien tidak tumpang tindih: fold 1–8 untuk pelatihan, fold 9 untuk validasi (pemilihan ambang), dan fold 10 untuk uji (2.158 EKG).

Alur pengembangan:

1. **Pra-pemrosesan:** sinyal dibaca dari format WFDB, kode SCP dipetakan ke 5 superclass (NORM, MI, STTC, CD, HYP), lalu dinormalisasi per sadapan. Offset DC tiap sadapan dibuang per jendela 10 detik.
2. **Baseline ML klasik:** 174 fitur buatan tangan (statistik amplitudo, daya spektral, laju jantung, variabilitas RR, usia, jenis kelamin) dengan *gradient boosting*.
3. **Deep learning:** 1D ResNet yang membaca sinyal mentah, lalu diperluas menjadi model multi-tugas 58 label.
4. **Pengukuran berbasis aturan:** interval, aksis, irama, dan pola yang tidak ada di data latih.
5. **Penggabungan:** laporan 8 kategori sesuai sistematika interpretasi EKG klinis.
6. **Uji eksternal:** data Holter INCART [20], rekaman VF CUDB [21], dan EKG cetak yang didigitalisasi dari gambar [22].

4.2 Dataset PTB-XL

PTB-XL [17] adalah kumpulan EKG klinis 12 sadapan terbuka terbesar yang tersedia saat dataset ini dirilis. Rekamannya dikumpulkan dengan perangkat Schiller AG di Physikalisch-Technische Bundesanstalt (Jerman) pada 1989–1996.

- **Ukuran:** 21.799 rekaman 10 detik dari 18.869 pasien, tersedia dalam 500 Hz dan 100 Hz. Penelitian ini memakai versi 100 Hz (1.000 sampel per sadapan).
- **Pasien yang dipakai:** 21.388 rekaman dari 18.617 pasien yang memiliki minimal satu label diagnostik. Usia median 61 tahun (IQR 50–72), 51,9% laki-laki.

- **Label:** 71 pernyataan SCP-ECG (diagnostik, bentuk gelombang, dan irama) yang diberikan oleh hingga dua kardiolog, masing-masing dengan tingkat keyakinan. Sebanyak 74,3% rekaman telah divalidasi manusia.
- **Superclass:** kode diagnostik dikelompokkan ke 5 superclass sesuai tabel `scp_statements.csv`. Satu EKG dapat memiliki lebih dari satu superclass: 16.244 rekaman berlabel 1 superclass, 4.068 berlabel 2, 919 berlabel 3, dan 157 berlabel 4.
- **Fold:** dataset menyediakan 10 fold bertingkat (*stratified*) per pasien, jadi rekaman dari pasien yang sama tidak pernah tersebar di fold berbeda. Fold 9 dan 10 berisi rekaman berkualitas label lebih tinggi sehingga disarankan sebagai set validasi dan uji.

Superclass	Latih (fold 1–8)	Validasi (fold 9)	Uji (fold 10)	Prevalensi
NORM — EKG normal	7.596	955	963	44,5%
MI — infark miokard	4.379	540	550	25,6%
STTC — perubahan ST/T	4.186	528	521	24,5%
CD — gangguan konduksi	3.907	495	496	22,9%
HYP — hipertrofi	2.119	268	262	12,4%
Jumlah rekaman	**17.084**	**2.146**	**2.158**	

Distribusi kelas yang tidak seimbang (HYP hanya 12,4%) menjadi alasan evaluasi memakai AUC dan PPV per kelas, bukan akurasi keseluruhan.

4.3 Pra-pemrosesan Sinyal

Setiap rekaman diubah menjadi tensor 12 × 1.000 dengan langkah berikut (`src/prep.py`, `src/train_full.py`):

1. **Membaca sinyal:** berkas WFDB 100 Hz dibaca dengan pustaka `wfdb` menjadi matriks 1.000 sampel × 12 sadapan dalam milivolt, dengan urutan I, II, III, aVR, aVL, aVF, V1–V6.
2. **Membuat label:** kolom `scp_codes` diurai. Kode diagnostik dipetakan ke superclass, dan 411 rekaman tanpa kode diagnostik dibuang. Untuk model 58 label, setiap kode SCP dengan ≥ 50 contoh (53 kode) dijadikan label biner terpisah.
3. **Membuang offset DC:** median tiap sadapan dikurangkan dari sinyalnya sehingga garis dasar berada di 0 mV. Langkah ini ditambahkan untuk model 58 label setelah uji pada data Holter menunjukkan offset hingga belasan mV; pada PTB-XL, langkah ini tidak mengubah AUC (0,9275 → 0,9273).
4. **Normalisasi z-score per sadapan:** rerata (μ) dan simpangan baku (σ) dihitung **hanya dari data latih** untuk mencegah kebocoran informasi ke set uji. Nilai σ sadapan ekstremitas 0,14–0,16 mV, sedangkan sadapan prekordial 0,23–0,33 mV karena

amplitudo QRS prekordial lebih besar.

5. **Format tensor:** matriks ditranspos menjadi 12 kanal × 1.000 sampel (*channel-first*), format masukan konvolusi 1D.

Saat inferensi pada rekaman lain, sinyal lebih dulu di-*resample* ke 100 Hz (filter polifase) lalu dipotong menjadi jendela 10 detik dengan pergeseran 5 detik (10 detik bila rekaman > 60 detik). Probabilitas semua jendela dirata-rata.

4.4 Rekayasa Fitur dan Baseline Machine Learning Klasik

Baseline mewakili pendekatan ML klasik (BAB II.2): manusia merancang fitur, lalu model belajar dari fitur tersebut (`src/train_ml.py`). Dari tiap EKG diekstraksi **174 fitur**:

Kelompok fitur	Isi	Jumlah
Statistik amplitudo per sadapan	rerata, simpangan baku, minimum, maksimum, puncak-ke-puncak, *skewness*, *kurtosis*, persentil 5 dan 95, rerata selisih absolut antarsampel	10 × 12 = 120
Daya spektral per sadapan (metode Welch)	log daya pada pita 0,5–3, 3–8, 8–15, dan 15–40 Hz	4 × 12 = 48
Irama (puncak R di sadapan II)	frekuensi jantung, simpangan baku RR, koefisien variasi RR, jumlah puncak R	4
Demografi	usia, jenis kelamin	2

Klasifikasinya memakai *histogram gradient boosting* (scikit-learn; 400 iterasi, *learning rate* 0,05), satu model biner per superclass (*binary relevance*) karena tugasnya multi-label. Baseline dilatih pada fold 1–9 dan diuji pada fold 10.

Kelemahan pendekatan ini terlihat dari rancangannya: fitur statistik tidak tahu letak gelombang Q, segmen ST, atau gelombang T, padahal di sanalah tanda infark dan iskemia berada.

4.5 Arsitektur 1D ResNet

Model *deep learning* adalah *residual network* satu dimensi, keluarga arsitektur yang menurut tolok ukur PTB-XL termasuk paling kuat untuk EKG [18]. Masukannya sinyal mentah 12 × 1.000 tanpa fitur buatan tangan.

Lapisan	Operasi	Bentuk keluaran	Parameter
Masukan	12 sadapan × 10 s pada 100 Hz	12 × 1.000	—
Stem	Conv1D 64 filter, kernel 15, stride 2 → BatchNorm → ReLU → MaxPool 3/2	64 × 250	11.648
Blok residual 1–2	2 × (Conv1D kernel 7 → BN → ReLU) + jalur pintas identitas	64 × 250	2 × 57.600
Blok residual 3	sama, stride 2, 128 filter; jalur pintas Conv 1×1	128 × 125	180.992
Blok residual 4	sama, 128 filter	128 × 125	229.888
Blok residual 5	stride 2; jalur pintas Conv 1×1	128 × 63	246.528
Blok residual 6	sama, 128 filter	128 × 63	229.888
Pooling global	rerata + maksimum sepanjang waktu, digabung	256	—
Kepala	Dropout 0,3 → Linear → sigmoid per label	5 atau 58	1.285 / 14.906
Total			**1.015.429 / 1.029.050**

Tiga pilihan desain yang penting:

- **Jalur pintas (*skip connection*):** keluaran tiap blok adalah ReLU(F(x) + x). Gradien dapat mengalir langsung lewat jalur pintas sehingga jaringan dalam tetap mudah dilatih.
- **Kernel 7 setelah *downsampling*:** setelah *stem*, satu sampel mewakili 40 ms, sehingga kernel 7 mencakup ±280 ms, cukup untuk satu kompleks QRS beserta segmen ST di sekitarnya. Lapisan yang lebih dalam menggabungkan pola tersebut menjadi pola berjangka lebih panjang (irama, hubungan P–QRS).
- ***Pooling* rerata + maksimum dan keluaran sigmoid:** pooling rerata menangkap pola yang konsisten di semua denyut, sedangkan pooling maksimum menangkap kejadian sesaat seperti PVC. Keluaran sigmoid (bukan softmax) memungkinkan satu EKG positif untuk beberapa label sekaligus.

4.6 Prosedur Pelatihan

Karena tiap EKG dapat memiliki beberapa label sekaligus, model dilatih dengan *binary cross-entropy* yang dirata-rata atas K label, dengan $p_k = \text{sigmoid}(z_k)$ sebagai probabilitas label k:

$\mathbf{L = -(1/K) \cdot \Sigma_k [\, y_k \cdot \log p_k + (1 - y_k) \cdot \log(1 - p_k) \,]}$, dengan $y_k = 1$ bila label k positif dan K = jumlah label (5 atau 58).

Hiperparameter	Model 5 kelas	Model 58 label
Inisialisasi	acak (seed 0)	backbone + 5 keluaran dari model 5 kelas
Optimizer	AdamW, *weight decay* 0,01	AdamW, *weight decay* 0,01
Jadwal laju belajar	*one-cycle*, puncak 3×10^{-3}	*one-cycle*, puncak 2×10^{-3}
Ukuran batch	64	64
Epoch	20	14
Pemilihan checkpoint	AUC makro validasi tertinggi	jumlah AUC superclass + AUC kode tertinggi
Perangkat	CPU 2 inti, tanpa GPU	CPU 2 inti, tanpa GPU
Waktu per epoch	±85 detik	±95 detik

Augmentasi data diterapkan acak pada setiap batch selama pelatihan:

1. **Skala amplitudo:** dikalikan faktor ~N(1; 0,1) per rekaman, meniru perbedaan kalibrasi dan habitus tubuh.
2. **Derau Gauss:** σ = 0,02 (satuan ternormalisasi), meniru derau otot dan elektrode.
3. **Geser waktu:** sinyal digeser melingkar hingga ±0,5 detik, agar model tidak bergantung pada posisi denyut di dalam jendela.

Jadwal *one-cycle* menaikkan laju belajar secara bertahap di awal lalu menurunkannya hingga mendekati nol di akhir pelatihan. Pola ini umumnya mempercepat konvergensi. Setiap akhir epoch, model dievaluasi pada set validasi (fold 9); bobot terbaik disimpan. Set uji (fold 10) tidak disentuh sampai evaluasi akhir.

4.7 Model Multi-Tugas 58 Label

Model 5 kelas hanya menjawab "kelompok diagnosis apa". Untuk laporan yang lebih rinci, model kedua dilatih memprediksi 5 superclass dan 53 kode SCP sekaligus (`src/train_full.py`) melalui *transfer learning*:

1. **Inisialisasi:** seluruh bobot konvolusi dan 5 baris pertama lapisan keluaran disalin dari model 5 kelas. Ke-53 baris keluaran baru diinisialisasi acak.
2. **Label kode:** sebuah kode dianggap positif bila tercantum di `scp_codes` rekaman itu, berapa pun tingkat keyakinannya. Kode `NORM` tidak dihitung ulang karena sudah ada sebagai superclass.
3. **Pelatihan bersama:** semua lapisan dilatih ulang 14 epoch dengan prosedur di 4.6. Berbagi *backbone* membuat kode jarang ikut memanfaatkan representasi yang dipelajari dari kode yang sering.
4. **Pemilihan model:** epoch 12 dipilih karena memberi jumlah AUC validasi superclass (0,932) dan kode (0,929) tertinggi.

Kode dengan < 50 contoh (antara lain flutter atrium, blok AV derajat 2 dan 3, takikardia supraventrikular) tidak dimasukkan karena terlalu sedikit untuk dipelajari dan dievaluasi secara bermakna. Pola tersebut ditangani modul aturan (4.9).

4.8 Evaluasi dan Pemilihan Ambang

Keluaran model berupa probabilitas 0–1 per label. Evaluasi dilakukan dalam dua lapis:

- **Tanpa ambang — AUC ROC:** peluang model memberi skor lebih tinggi pada EKG positif dibanding EKG negatif yang dipilih acak. AUC tidak dipengaruhi prevalensi sehingga adil untuk membandingkan kelas yang jarang dan yang sering. Macro AUC adalah rerata AUC semua label.
- **Dengan ambang — sensitivitas, spesifisitas, PPV:** untuk menyatakan "positif/negatif" di laporan, tiap label membutuhkan ambang. Ambang **dipilih pada set validasi**, bukan set uji, agar hasil uji tidak bias.

Cara memilih ambang dibedakan menurut jenis label:

1. **Superclass — indeks Youden** (J = sensitivitas + spesifisitas − 1, dimaksimalkan). Pilihan ini menyeimbangkan sensitivitas dan spesifisitas dan cocok untuk kelas yang cukup sering.
2. **Kode rinci — F1 maksimum**, minimal 0,10. F1 memberi bobot pada PPV sehingga positif palsu berkurang dibanding indeks Youden. Namun, pada kode dengan sangat sedikit contoh validasi, F1 pun menghasilkan ambang yang terlalu rendah (QT memanjang 0,02; efek elektrolit 0,04) dan memicu positif palsu. Karena itu ditetapkan batas bawah 0,10.

Set uji (fold 10, 2.158 EKG) hanya dipakai sekali untuk angka akhir. Untuk interpretabilitas, dibuat **peta saliency**: gradien probabilitas terhadap sinyal masukan, yang menunjukkan bagian EKG yang paling memengaruhi keputusan model. Pada contoh EKG infark, saliency terkonsentrasi di kompleks QRS dan segmen ST–T, sesuai lokasi tanda infark secara klinis.

4.9 Pengukuran Berbasis Aturan dan Laporan 8 Kategori

Model hanya mengenal diagnosis yang ada di data latih. Banyak kategori klinis penting, seperti fibrilasi ventrikel, asistol, takikardia ventrikel, dan blok AV derajat 2/3, tidak ada atau sangat jarang di PTB-XL. Karena itu penulis menambahkan modul pengukuran berbasis aturan yang meniru langkah pembacaan EKG sistematis:

1. **Kualitas sinyal:** sadapan datar (simpangan baku < 0,01 mV) atau bising; bila ≥ 4 sadapan datar, EKG dinyatakan tidak dapat dibaca.
2. **Deteksi QRS:** energi turunan gabungan 12 sadapan (mirip algoritma Pan–Tompkins), lalu frekuensi jantung dan keteraturan RR.
3. **Median beat:** dari median beat diukur awal/akhir QRS, interval PR, QT dengan metode tangen, QTc (Bazett dan Fridericia), aksis listrik dari area QRS di I dan aVF, voltase Sokolow–Lyon dan Cornell, serta deviasi ST pada J+40 ms.
4. **Pola tanpa data latih:** asistol (amplitudo median < 0,1 mV), fibrilasi ventrikel (> 70% daya spektral di 3–8 Hz dengan interval tidak teratur), takikardia kompleks lebar, irama junctional/idioventrikular, flutter atrium (aktivitas atrium 250–400/menit), dan blok AV derajat 2/3 (gelombang P lebih banyak daripada QRS).

Hasil model dan pengukuran digabung menjadi **laporan 8 kategori**: interpretasi umum, irama sinus, irama atrium, irama junctional, blok AV, irama ventrikel, konduksi dan aksis, serta iskemia/infark/hipertrofi/QT. Setiap butir menyebut sumbernya (model beserta AUC ujinya, atau pengukuran beserta angkanya) dan status cakupannya.

Validasi pengukuran (2.158 EKG uji PTB-XL vs label kardiolog)	Sensitivitas	PPV
Sinus takikardia (> 100/menit)	0,94	0,75
Fibrilasi atrium (RR tidak teratur tanpa P)	0,58	0,92
Deviasi aksis kiri vs hemiblok anterior kiri	0,80	0,58
Depresi ST (≤ −0,1 mV, ≥ 2 sadapan bersebelahan)	0,19	0,17
Inversi gelombang T	0,31	0,08

Pengukuran definisional (frekuensi, aksis, keteraturan RR) cukup akurat. Median EKG normal: PR 180 ms, QRS 90 ms, QTc 397 ms, sesuai rentang normal. Sebaliknya, aturan ST/T, PVC, dan voltase LVH menghasilkan terlalu banyak positif palsu. Karena itu, untuk temuan tersebut laporan memakai keluaran model, bukan aturan.

4.10 Aplikasi: Pembaca EKG

Sistem dikemas dalam tiga bentuk yang memakai model dan aturan yang sama:

- **Halaman web (JavaScript murni):** bobot model (float16, ±2 MB) dan pengukuran dijalankan langsung di browser, jadi data EKG tidak dikirim ke mana pun. Hasilnya identik dengan versi Python (selisih probabilitas ⩽ 0,001; pengukuran identik pada 292 dari 300 EKG uji, sisanya hanya berbeda pembulatan).
- **`python3 main.py`:** satu perintah yang menyiapkan lingkungan Python, menguji model pada contoh, lalu membuka web di `localhost:8000`. Di mode ini prediksi dijalankan PyTorch melalui API `/api/predict`.
- **Baris perintah:** `python3 main.py file.csv --fs 257` mencetak tabel probabilitas, pengukuran, dan laporan 8 kategori.

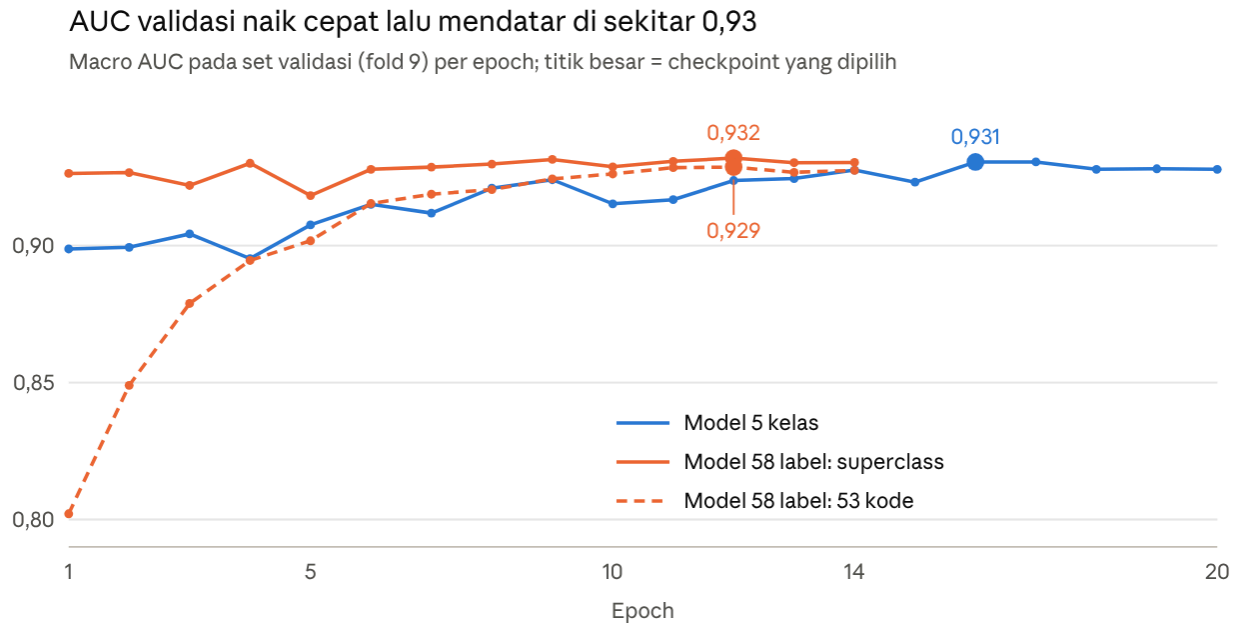
Input yang diterima adalah CSV 12 kolom (mV) atau format WFDB, dengan frekuensi sampling bebas (diubah ke 100 Hz), durasi 5 detik sampai 10 menit. Kolom waktu, satuan µV, dan data yang tertukar baris-kolom dideteksi otomatis. Tampilan EKG mengikuti kertas standar 25 mm/s dan 10 mm/mV dengan format 3×4 plus strip irama.

Untuk transparansi, server mencatat setiap prediksi di terminal (waktu per tahap, ukuran data, kesimpulan), dan web menampilkan panel performa. Pada laptop 2 inti, rekaman Holter 5 menit (30 jendela) selesai dalam ±0,2 detik di server PyTorch, atau ±9–10 detik bila seluruhnya dihitung di browser. Di server, waktu habis terutama untuk membaca CSV dan *resampling*, bukan inferensi model.

BAB V — Hasil dan Pembahasan Implementasi

5.1 Kurva Pelatihan

Kedua model konvergen: AUC validasi naik paling cepat di 5 epoch pertama, lalu mendatar di sekitar 0,93.



res_dl.json & full_res.json (repositori, folder hasil/) · AUC validasi fold 9, 20 dan 14 epoch

- **Model 5 kelas:** *loss* latih turun terus dari 0,423 ke 0,189, sedangkan AUC validasi naik dari 0,899 (epoch 1) ke puncak 0,931 di epoch 16, lalu stabil di 0,928. AUC validasi tidak turun meski *loss* latih terus menurun, jadi *overfitting* di akhir pelatihan paling banter ringan. Checkpoint epoch 16 dipakai.
- **Model 58 label:** karena berangkat dari bobot model 5 kelas, AUC superclass sudah 0,926 sejak epoch 1. Yang naik adalah AUC 53 kode rinci, dari 0,802 ke 0,929 di epoch 12, sebelum sedikit turun di epoch 13–14. Checkpoint epoch 12 dipakai.
- **Fluktuasi kecil** antar-epoch (mis. epoch 4–5 model 5 kelas) wajar karena augmentasi acak dan laju belajar yang tinggi di fase awal jadwal *one-cycle*.

5.2 Perbandingan Model: Machine Learning Klasik vs Deep Learning

CNN mengungguli ML klasik di kelima superclass (macro AUC 0,927 vs 0,887), dengan selisih terbesar pada infark miokard (0,859 → 0,929). Ini sejalan dengan teori bahwa *deep learning* menangkap pola morfologi yang sulit dirumuskan sebagai fitur manual (BAB II.2).

Superclass (data uji, n = 2.158)	ML klasik	CNN 5 kelas	CNN 58 label
NORM — EKG normal	0,913	0,948	0,947
MI — infark miokard	0,859	0,929	0,931
STTC — perubahan ST/T	0,906	0,939	0,941
CD — gangguan konduksi	0,872	0,921	0,920
HYP — hipertrofi	0,887	0,900	0,891

Superclass (data uji, n = 2.158)	ML klasik	CNN 5 kelas	CNN 58 label
Macro AUC	**0,887**	**0,927**	**0,926**

Hasil ini berada dalam kisaran yang dilaporkan tolok ukur PTB-XL untuk arsitektur ResNet [18]. Model ML klasik dilatih pada fold 1–9 (CNN fold 1–8), sehingga keunggulan CNN justru sedikit diremehkan.

Kinerja kode rinci bervariasi menurut jumlah contoh. Macro AUC 53 kode = 0,920. Ambang tiap kode dipilih dari F1 maksimum di set validasi, minimal 0,10.

Kode	n uji	AUC	Sensitivitas	Spesifisitas	PPV
LBBB komplit	54	0,997	0,98	1,00	0,88
RBBB komplit	54	0,997	0,96	0,99	0,74
PVC	113	0,990	0,89	0,99	0,77
Sinus takikardia	82	0,990	0,91	0,99	0,82
Fibrilasi atrium	144	0,982	0,82	0,99	0,89
Hemiblok anterior kiri	162	0,982	0,81	0,98	0,73
Infark anteroseptal	234	0,970	0,74	0,98	0,80
Blok AV derajat 1	79	0,968	0,54	0,98	0,57
LVH	214	0,942	0,52	0,97	0,68
Gangguan konduksi IV non-spesifik	79	0,733	0,19	0,98	0,23
QT memanjang	11	0,849	0,00	1,00	—

Kode dengan contoh sedikit (QT memanjang, WPW, infark lateral) hampir tidak pernah positif. Ini konsisten dengan BAB III.4: kinerja bergantung pada jumlah data berlabel.

5.3 Uji Eksternal

Pada data di luar PTB-XL, model mengenali kondisi yang dominan (infark akut, LVH, RBBB, fibrilasi atrium), tetapi juga menunjukkan *domain shift* yang jelas.

a. Rekaman Holter INCART [20]. Sebanyak 18 rekaman 12 sadapan (5 menit pertama, 257 Hz) dari 18 pasien berbeda diuji tanpa pelatihan ulang.

Kondisi menurut sumber	Rekaman	Terdeteksi oleh laporan
Infark miokard akut	I03, I62, I64	3/3 sebagai infark; elevasi ST 2/2 (I03, I62)
Hipertrofi ventrikel kiri	I20, I44, I72	3/3
RBBB	I16	1/1

Kondisi menurut sumber	Rekaman	Terdeteksi oleh laporan
Fibrilasi atrium (menetap)	I50	1/1
Sindrom WPW	I68, I71	1/2 (I71)
Blok AV derajat 2 Mobitz I	I09	0/1 (salah dibaca sebagai fibrilasi atrium)

Kelemahan utamanya: "hipertrofi ventrikel" juga muncul pada 7 dari 15 rekaman tanpa LVH. Penyebab yang mungkin adalah perbedaan penempatan elektroda Holter (Mason–Likar) dan amplitudo sinyal dibanding EKG istirahat PTB-XL. Hal ini mengonfirmasi BAB III.4: model harus divalidasi pada populasi dan alat yang akan dipakai.

b. Fibrilasi ventrikel (CU Ventricular Tachyarrhythmia Database [21]). Aturan VF mendeteksi 3/3 segmen VF, sementara tidak ada satu pun dari 2.158 EKG uji PTB-XL yang salah ditandai VF. Daya spektral 3–8 Hz pada VF adalah 0,79–0,91, sedangkan EKG PTB-XL maksimal 0,62. Asistol terdeteksi pada sinyal datar. Sebaliknya, heuristik takikardia ventrikel **gagal** pada run VT nyata di INCART (I30), karena lebar QRS terukur hanya 90 ms.

c. EKG cetak hasil digitalisasi [22]. Gambar EKG 12 sadapan dari ECG Library (pria 83 tahun dengan stenosis aorta; diagnosis LVH dan abnormalitas atrium kiri) didigitalisasi menjadi CSV:

1. Skala dibaca dari pulsa kalibrasi (1 mV = 31 piksel; 0,2 s = 15 piksel, jadi 25 mm/s).
2. Jejak tiap baris ditelusuri per kolom piksel dari garis dasarnya, dan garis pemisah antar-kolom dibuang.
3. Karena format cetak 3×4 hanya memuat 2,5 detik per sadapan, sisa 10 detik diisi median beat sadapan itu pada waktu detak dari strip irama V1 (11 detak, 63/menit).

Laporan menghasilkan irama sinus 63/menit dengan **LVH (p = 0,61)**, sesuai diagnosis sumber, plus perubahan ST/iskemia non-spesifik yang sesuai pola *strain*. Abnormalitas atrium kiri tidak terdeteksi, kemungkinan karena resolusi gambar rendah (±3 piksel/mm) sehingga komponen terminal gelombang P di V1 hilang.

5.4 Keterbatasan dan Repositori

- **Belum didukung:** kontraksi junctional prematur, Torsades de Pointes, dan pembedaan Mobitz I vs II. Deteksi takikardia ventrikel juga belum andal.
- **Resolusi interval:** interval diukur pada 100 Hz (resolusi 10 ms) dari median beat. Hasilnya perkiraan, tidak setara pembacaan manual.
- **Validasi terbatas:** heuristik untuk pola yang tidak ada di PTB-XL (blok AV derajat 2/3, flutter, irama junctional, AIVR) belum diuji pada rekaman nyata dengan kondisi tersebut.

- **Satu sumber data latih** (Jerman, EKG istirahat). Uji INCART menunjukkan positif palsu hipertrofi pada data Holter, dan belum ada validasi pada populasi Indonesia.
- **Alat belajar:** sistem ini tidak memiliki izin edar sebagai perangkat medis dan tidak boleh dipakai untuk keputusan klinis (BAB III.5).

Repositori neccrr/ekg-readings-model berisi kode pra-pemrosesan, pelatihan, evaluasi, prediksi, pengukuran, dan laporan; bobot kedua model; notebook Google Colab; aplikasi web; contoh input (PTB-XL dan EKG hasil digitalisasi); serta metrik lengkap tiap kode. Satu perintah `python3 main.py` menyiapkan lingkungan dan menjalankan aplikasi di komputer pengguna.

Langkah reproduksi pelatihan dari nol (unduh PTB-XL, pra-pemrosesan, pelatihan kedua model, finalisasi ambang) beserta kurva pelatihan dan hiperparameter lengkap didokumentasikan di `docs/TRAINING.md` pada repositori yang sama.

BAB VI — Penutup

6.1 Kesimpulan

1. *Machine learning* klasik bergantung pada fitur buatan manusia, *deep learning* belajar langsung dari sinyal EKG mentah, dan LLM multimodal menafsirkan gambar EKG bersama teks dalam bahasa alami.
2. Model *deep learning* khusus EKG telah mencapai kinerja setara kardiolog dalam klasifikasi aritmia dan mampu mendeteksi kondisi "tersembunyi" seperti disfungsi ventrikel kiri (AUC 0,93), fibrilasi atrium paroksismal (AUC 0,87), dan hiperkalemia (AUC hingga 0,88).
3. Uji klinis acak EAGLE membuktikan manfaat nyata AI-EKG di layanan primer, yaitu peningkatan diagnosis EF rendah tanpa penambahan ekokardiografi yang bermakna.
4. LLM multimodal generalis belum andal untuk interpretasi EKG mandiri (akurasi sekitar 50–65%, sensitivitas temuan kritis rendah, jawaban tidak konsisten), tetapi berpotensi sebagai lapisan penjelas dan alat bantu belajar setelah diadaptasi.
5. Penerapan klinis memerlukan validasi lokal, pengendalian bias, perlindungan data, dan pengawasan dokter.
6. Implementasi penulis (BAB IV–V) mereplikasi temuan literatur: 1D ResNet mengungguli ML klasik (macro AUC 0,927 vs 0,887) dan mengenali BBB, PVC, serta fibrilasi atrium dengan AUC ⩾ 0,98. Uji pada data Holter dan EKG hasil digitalisasi menunjukkan bahwa model mengenali kondisi dominan, tetapi rentan terhadap *domain shift* dan buta terhadap kondisi yang tidak ada di data latih. Kekurangan itu sebagian dapat ditutup dengan pengukuran berbasis aturan.

6.2 Saran

- **Bagi mahasiswa kedokteran:** tetap kuasai interpretasi EKG secara sistematis; gunakan AI sebagai pembanding, bukan pengganti penalaran klinis.
- **Bagi institusi pendidikan:** masukkan literasi AI dan penilaian kritis studi diagnostik ke dalam kurikulum.
- **Bagi peneliti di Indonesia:** bangun basis data EKG digital lokal yang terhubung dengan data klinis untuk validasi model pada populasi Indonesia.
- **Bagi pembuat kebijakan:** susun kerangka regulasi perangkat lunak medis berbasis AI dan dukung uji klinis implementasi di layanan primer.

Daftar Pustaka

Sumber jurnal ditelusuri melalui PubMed; dataset dari PhysioNet.

1. Siontis KC, Noseworthy PA, Attia ZI, dkk. Artificial intelligence-enhanced electrocardiography in cardiovascular disease management. *Nat Rev Cardiol*. 2021;18(7):465–478. doi:10.1038/s41569-020-00503-2
2. Hannun AY, Rajpurkar P, Haghpanahi M, dkk. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nat Med*. 2019;25(1):65–69. doi:10.1038/s41591-018-0268-3
3. Ribeiro AH, Ribeiro MH, Paixão GMM, dkk. Automatic diagnosis of the 12-lead ECG using a deep neural network. *Nat Commun*. 2020;11(1):1760. doi:10.1038/s41467-020-15432-4
4. Attia ZI, Kapa S, Lopez-Jimenez F, dkk. Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram. *Nat Med*. 2019;25(1):70–74. doi:10.1038/s41591-018-0240-2
5. Yao X, Rushlow DR, Inselman JW, dkk. Artificial intelligence-enabled electrocardiograms for identification of patients with low ejection fraction: a pragmatic, randomized clinical trial. *Nat Med*. 2021;27(5):815–819. doi:10.1038/s41591-021-01335-4
6. Attia ZI, Noseworthy PA, Lopez-Jimenez F, dkk. An artificial intelligence-enabled ECG algorithm for the identification of patients with atrial fibrillation during sinus rhythm: a retrospective analysis of outcome prediction. *Lancet*. 2019;394(10201):861–867. doi:10.1016/S0140-6736(19)31721-0
7. Galloway CD, Valys AV, Shreibati JB, dkk. Development and validation of a deep-learning model to screen for hyperkalemia from the electrocardiogram. *JAMA Cardiol*. 2019;4(5):428–436. doi:10.1001/jamacardio.2019.0640

8. Attia ZI, Friedman PA, Noseworthy PA, dkk. Age and sex estimation using artificial intelligence from standard 12-lead ECGs. *Circ Arrhythm Electrophysiol*. 2019;12(9):e007284. doi:10.1161/CIRCEP.119.007284
9. Harmon DM, Carter RE, Cohen-Shelly M, dkk. Real-world performance, long-term efficacy, and absence of bias in the artificial intelligence enhanced electrocardiogram to detect left ventricular systolic dysfunction. *Eur Heart J Digit Health*. 2022;3(2):238–244. doi:10.1093/ehjdh/ztac028
10. Soubh, Rasenack, Haarmann, dkk. Performance of vision-enabled large language models in image-based electrocardiogram interpretation: exploratory evaluation. *J Med Internet Res*. 2026;28:e86692. doi:10.2196/86692
11. Stelling, Kraus, Grieb, dkk. Artificial intelligence for biomedical diagnostics: diagnostic accuracy and reliability of multimodal large language models in electrocardiogram interpretation. *Life (Basel)*. 2026;16(4):681. doi:10.3390/life16040681
12. Legendre, Cvek, Greathouse, dkk. Large language models fail to reliably predict emergent catheterization laboratory activation from prehospital electrocardiograms. *Heart Lung*. 2026;80:102956. doi:10.1016/j.hrtlng.2026.102956
13. Cheng, Wang, Zhang, dkk. Differentiating ischemic from nonischemic T-wave inversion using a multimodal vision-language model with reinforcement learning (ECG-R1): development and validation study. *JMIR Med Inform*. 2026;14:e87227. doi:10.2196/87227
14. Costa, Otero, García Iglesias, dkk. Few-shot ECG analysis with large vision language models in data-scarce clinical settings. *Comput Biol Med*. 2026;213:111816. doi:10.1016/j.compbiomed.2026.111816
15. Jiang, Adhikari, Bernard, dkk. Interpreting ECG images with multimodal large language models. *Stud Health Technol Inform*. 2026;336:959–963. doi:10.3233/SHTI260321
16. Matsumoto, Fujisaki, Higuchi, dkk. Large language model-based localization of premature ventricular contraction origins: a retrospective diagnostic accuracy study. *J Cardiovasc Electrophysiol*. 2026. doi:10.1111/jce.70464
17. Wagner P, Strodthoff N, Bousseljot RD, dkk. PTB-XL, a large publicly available electrocardiography dataset. *Sci Data*. 2020;7(1):154. doi:10.1038/s41597-020-0495-6
18. Strodthoff N, Wagner P, Schaeffter T, Samek W. Deep learning for ECG analysis: benchmarks and insights from PTB-XL. *IEEE J Biomed Health Inform*. 2021;25(5):1519–1528. doi:10.1109/JBHI.2020.3022989
19. Goldberger AL, Amaral LAN, Glass L, dkk. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. *Circulation*. 2000;101(23):e215–e220.
20. St Petersburg INCART 12-lead Arrhythmia Database. PhysioNet. physionet.org/content/incartdb/1.0.0

21. CU Ventricular Tachyarrhythmia Database. PhysioNet. physionet.org/content/cudb/1.0.0
22. ECG Library. Left ventricular and left atrial hypertrophy. ecglibrary.com/lvhlah.html